

Uygulamalı Yapay Zekâ Geliştirme Bootcamp - 2. Hafta Ödevi

Ad Soyad: Havva YAMAN

Tarih: 23.09.2026

1. ML Proje Yaşam Döngüsü

- **Problem Tanımı:** Projenin iş amacını belirleme, çözülecek sorunun sınıflandırma mı yoksa regresyon mu olduğunu netleştirme adımıdır.
- **Veri Toplama:** Çözüme uygun CSV, API, veri tabanları veya log kayıtları gibi ham veri kaynaklarının bir araya getirilme sürecidir.
- **Veri Hazırlama:** Pandas kütüphanesi kullanılarak eksik verilerin (Missing Values), mükerrer kayıtların ve sapan değerlerin (Outlier) temizlenip verinin ölçeklendiği aşamadır.
- **Model Seçimi:** Problemin türüne göre (örneğin e-posta tespiti için Logistic Regression veya Random Forest) kullanılacak algoritmaların belirlenmesidir.
- **Eğitim (Training):** Seçilen algoritmanın model.fit() komutuyla eğitim verisindeki özellikleri inceleyerek örüntüleri matematiksel olarak öğrenme safhasıdır.
- **Test / Değerlendirme:** Eğitilen modelin daha önce hiç görmediği test verileri üzerindeki başarı metriklerinin (Accuracy, F1-Score) ölçüldüğü adımdır.
- **Kullanım (Inference):** Tamamen hazır hale gelen modelin canlı sisteme (entegrasyona) alınarak yeni gelen veriler için anlık ve gerçek zamanlı tahminler üretmesi aşamasıdır.

2. Dataset İnceleme

Bu ödev kapsamında, ders materyallerimizde de yer alan ve GitHub reposunda paylaşılan **ornek_email_spam.csv** veri seti incelenmiştir. Veri setinin temel amacı, e-postaların içerik yapısal özelliklerine bakarak mesajın spam olup olmadığını (0: Normal, 1: Spam) tahmin etmektir. Veri seti yaklaşık 1000 satırdan ve e-postaların yapısal ipuçlarını barındıran 7 sütundan (feature) oluşmaktadır. Model tarafından tahmin edilmek istenen hedef alan (Label) ise e-postanın türünü belirten **spam** sütunudur.

3. Train / Validation / Test

Bir makine öğrenmesi modelinde verilerin tek bir parça yerine üç ayrı kümeye bölünmesinin temel sebebi, modelin veriyi ezberlemesini (Overfitting) önlemek ve gerçek dünya başarısını tarafsız ölçmektir. **Train (Eğitim) seti**, modelin içerideki ağırlıkları ve katsayıları doğrudan öğrendiği, tabiri caizse ders çalıştığı ana büyük veri kümesidir. **Validation (Doğrulama) seti**, eğitim devam ederken modelin hiperparametre ayarlarını (GridSearchCV gibi) yapmak ve en iyi model varyasyonunu seçmek için kullanılan ara kontrol kümesidir. **Test seti** ise modelin eğitim süresince kapısına hiç uğramadığı, sınav günü gibi karşısına çıkarılan ve modelin nihai genelleme yeteneğini ölçen son tarafsız veri kümesidir.

4. Algoritmaları Tanıma

- **Linear Regression (Doğrusal Regresyon):** Ev fiyatı tahmini veya sıcaklık tahmini gibi, ucu açık ve sürekli sayısal değerlerin tahmin edilmek istendiği **Regresyon** problemlerinde kullanılır.

- **Logistic Regression (Lojistik Regresyon):** E-postanın spam olup olmaması veya müşterinin terk edip etmeyeceği gibi iki sınıflı (Evet/Hayır) **Kategorik Sınıflandırma** problemlerinde kullanılır.
- **Decision Tree (Karar Ağacı):** Veriyi yukarıdan aşağıya doğru belirli sorularla (if-else mantığıyla) dallara ayırarak hem **Sınıflandırma** hem de **Regresyon** problemlerinde güçlü sonuçlar üreten ağaç tabanlı bir algoritmadır.
- **Random Forest (Rastgele Orman):** Birden fazla karar ağacının rastgele alt veri kümeleriyle eğitilip ortak bir oylama yapması prensibiyle çalışan, ezberlemeye karşı dirençli hem **Sınıflandırma** hem de **Regresyon** algoritmasıdır.

5. Overfitting / Underfitting

- **Underfitting (Yetersiz Öğrenme):** Modelin verideki ilişkileri ve örüntüleri anlayamayacak kadar basit kalması, hem eğitim hem de test verisinde çok düşük başarı göstermesi durumudur. *Benzetme:* Sınava hiç çalışmamış, formülleri bile bilmeyen bir öğrencinin sınavda kalması Underfitting'e benzer.
- **Overfitting (Aşırı Öğrenme / Ezberleme):** Modelin eğitim verisindeki tüm detayları, gürültüleri ve hatta hataları tamamen ezberlemesi; bu yüzden eğitim setinde %100 başarılı olurken test setinde çökmesi durumudur. *Benzetme:* Sınavdan önceki test kitabındaki soruların cevap şıklarını (A, B, C diye) tamamen ezberleyen ama sınavda soruların sayıları azıcık değiştiğinde hiçbir soruyu çözemeyen öğrencinin durumu Overfitting örneğidir.

6. Başarı Metrikleri

- **Accuracy (Doğruluk):** Modelin doğru tahmin ettiği tüm kayıtların, veri setindeki toplam kayıt sayısına olan genel oranıdır.
- **Precision (Kesinlik):** Modelin "Spam" veya "Hasta" dediği tahminlerin ne kadarının gerçekten doğru çıktığını gösteren, yani yalancı pozitifleri (FP) denetleyen metriktir.
- **Recall (Duyarlılık):** Gerçekte "Spam" veya "Hasta" olan tüm durumların model tarafından yüzde kaçının başarıyla yakalanabildiğini (kaçırılmadığını) ölçen metriktir.
- **F1-Score:** Precision ve Recall metriklerinin harmonik ortalaması olup, veri setindeki sınıflar dengesiz olduğunda modelin gerçek kalitesini gösteren dengeli metriktir.
- *Hastalık Tespiti Örneği:* 100 kişilik bir grupta 99 kişi sağlıklı, 1 kişi ölümcül hasta olsun. Model herkese hiç bakmadan "Sağlıklı" derse genel Doğruluk (Accuracy) oranı otomatik olarak %99 çıkar ve çok başarılı görünür. Ancak model o 1 tane gerçek hastayı kaçırdığı için aslında görevini tamamen başarısız yapmıştır; işte bu yüzden ölümcül durumlarda sadece Accuracy değerine bakmak bizi felakete sürükleyebilir, Recall değerinin incelenmesi şarttır.

7. Confusion Matrix (Hata Matrisi)

Confusion Matrix, sınıflandırma modellerinin yaptığı doğru ve yanlış tahminlerin performansını satır ve sütunlar halinde gösteren bir özet tablosudur. Kavramların dün terminalde bizzat koşturduğumuz spam e-posta projesi üzerindeki karşılıkları şöyledir:

- **TP (True Positive - Doğru Pozitif):** Modelin bir e-postaya "Spam" tahmini yapması ve o e-postanın gerçekten spam (dolandırıcı) çıkması durumudur.

- **TN (True Negative - Doğru Negatif):** Modelin e-postaya "Normal/Güvenli" demesi ve e-postanın gerçekten arkadaşımızdan gelen normal bir mesaj çıkmasıdır.
- **FP (False Positive - Yalancı Pozitif):** Modelin normal bir e-postayı yanlışlıkla "Spam" kutusuna atması durumudur (İş dünyasında en tehlikeli hatalardan biridir).
- **FN (False Negative - Yalancı Negatif):** Modelin tehlikeli bir spam e-postayı gözden kaçırıp normal gelen kutumuza düşürmesi hatasıdır.

8. Mini ML Senaryosu (Spam Tespiti)

- **Problem Tipi:** İkili Sınıflandırma (Binary Classification - 0 veya 1 tahmini).
- **Olası Feature'lar (Özellikler):** E-postanın içindeki toplam kelime_sayisi, mesajdaki link_sayisi, büyük harfle yazılmış kelime oranı, gönderici hesabın güvenilirlik skoru ve "kampanya/bedava" gibi tetikleyici kelimelerin geçme sıklığı.
- **Label (Hedef Değişken):** E-postanın türü (0: Güvenli Mail, 1: Spam Mail).
- **Kullanılabilecek Algoritma:** Dün akşam PyCharm üzerinde requirements.txt kurulumunu yaparak bizzat koşturduğumuz ve en yüksek dengeleme başarısını sunan **Random Forest Classifier** algoritmasıdır.